

LA HORDE

Projet

GameMetrics

1. Contexte

GameMetrics est une petite structure de conseil qui aide des éditeurs à décider sur quelles plateformes et quels genres investir. Pour cela, elle s'appuie sur des données historiques de ventes de jeux vidéo, disponibles publiquement.

Le volume et la richesse de ces données rendent une analyse manuelle impossible. GameMetrics souhaite une chaîne de traitement Big Data en Java s'appuyant sur Hadoop pour en extraire des tendances exploitables.

2. Problématique

Développer en Java une chaîne de traitement Big Data s'appuyant sur Hadoop (HDFS + MapReduce) pour analyser un jeu de données public de ventes de jeux vidéo et en extraire des tendances exploitables.

3. Fonctionnalités à développer

- **Jeu de données** : un dataset public déjà existant et téléchargeable directement (au format CSV) - aucune génération de données n'est nécessaire.
- **Ingestion sur HDFS** ou traitement en mode pseudo-distribué local.
- **Jobs MapReduce en Java** : au moins 2 traitements différents (ex : total des ventes mondiales par genre, top éditeurs par décennie, évolution des ventes par plateforme et par année).
- **Couche service** : orchestration des jobs Hadoop, lecture et agrégation des résultats produits.
- **Restitution des résultats** : interface (console, JavaFX ou page web simple) affichant les tops et tendances calculés (classement par genre/plateforme, évolution dans le temps).
- **Gestion des erreurs** : lignes incomplètes ou mal formées du dataset (valeurs manquantes) détectées et écartées sans faire échouer le job.

4. Contraintes techniques

- Java 17+ (compatibilité Hadoop), projet Maven ou Gradle
- Hadoop en mode pseudo-distribué (local) ou cluster mono-nœud, HDFS pour le stockage du dataset et des résultats
- Architecture en couches : controller / service / repository / model
- Dataset public, déjà disponible et de taille raisonnable pour rester démontrable en local
- Application/démo exécutable localement

5. Déroulement de la soutenance

La soutenance dure 15 minutes et se déroule en deux temps :

- **Présentation (8-10 min)** : démarche Big Data, choix du dataset et des traitements, difficultés rencontrées avec Hadoop, axes d'amélioration
- **Démonstration** : exécution d'un job en direct (ou résultats pré-calculés commentés), y compris un cas d'erreur géré (ex : ligne du dataset incomplète)

Le jury peut à tout moment demander d'ouvrir le code, interroger sur un job précis, ou faire rejouer un traitement.

6. Critères d'évaluation

- **Présentation & clarté (25 pts)** : structure du discours, pédagogie, qualité du support
- **Démonstration fonctionnelle (30 pts)** : chaîne de traitement qui fonctionne, scénarios couverts, gestion des cas d'erreur
- **Maîtrise technique (30 pts)** : compréhension du code, justification des choix (jobs, architecture), réponses au jury
- **Conception de la chaîne de traitement (15 pts)** : cohérence de l'architecture (jobs/service/restitution), pertinence des choix de traitement